[PSI3472-2023. Aula 13 parte 1. Início]

I. One-Shot Learning

1. Introdução

Vamos seguir as explicações dos posts [<u>Brownlee2019</u>, <u>Lamba2019</u>, <u>Bouma2017</u>] para aprender sobre One-Shot Learning.

Já vimos que para fazer classificação com CNN é necessária uma grande quantidade de dados de treinamento. Por exemplo, para ensinar CNN a distinguir duas pessoas A e B, são necessárias muitas fotos das pessoas A e B. One-shot learning permite efetuar classificação a partir de poucas ou mesmo uma única imagem de treinamento (uma única foto da pessoa A e outra da pessoa B). Isto parece mágica, mas veremos que na verdade aprendizagem one-shot utilizou previamente uma grande quantidade de imagens para fazer um "pré-treino" para reconhecer se duas fotos se referem à mesma pessoa (ou não), de forma que mais tarde necessita de uma única imagem de treino por classe.

Considere uma empresa que quer instalar um sistema para fazer reconhecimento facial de seus funcionários. Para treinar um classificador CNN, são necessárias dezenas ou centenas de imagens de cada funcionário fotografado sob diferentes ângulos, iluminações, expressões faciais, penteados, etc. Porém, é complicado para empresa conseguir essa quantidade de fotos de cada funcionário. Além disso, mesmo que consiga muitas fotos de cada funcionário, se um funcionário está sem barba em todas as fotos-exemplos o sistema poderá não reconhecê-lo se um dia aparecer de barba.

Os problemas não terminam aí. Digamos que a empresa tinha 10 funcionários e treinou o sistema de reconhecimento de face fornecendo centenas fotografias de cada funcionário. O treino demorou várias horas de processamento. Aí a empresa contratou mais um funcionário. A empresa vai ter que refazer todo o treino novamente.

One-shot learning aprende, a partir de uma quantidade grande de fotos de pessoas, o que faz duas fotos serem de uma mesma pessoa. Isto é, aprende uma "função distância" que devolve valor baixo se as duas fotos forem da mesma pessoa e devolve valor alto se representarem duas pessoas diferentes. Este treino é feito previamente pelo fabricante do sistema de reconhecimento facial, longe do usuário final do sistema (aliás, há vários modelos gratuitos pré-treinados). Depois, basta inserir uma única foto (ou poucas fotos) de cada funcionário para poder verificar se a pessoa que está sendo fotografada pela câmera de segurança é a mesma pessoa (ou não) daquela armazenada no BD. Se a "função distância" tiver sido bem projetada, ela irá reconhecer a face independentemente de usar óculos ou não, de estar com barba ou não, de usar penteados diferentes, etc.

Se a empresa contratar um novo funcionário, basta adicionar uma única foto (ou poucas fotos) dele no BD que o sistema continuará funcionando sem a precisar repetir o treino. Se a empresa demitir um funcionário, bastará remover a foto do funcionário demitido do BD.

Outro exemplo de uso de "one-shot learning" é na verificação de assinatura. Basta ter poucas assinaturas de cada cliente para que o sistema possa verificar se uma dada assinatura é do cliente registrado (ou não). [Jade2022]

2. Banco de dados Omniglot

Seguindo [Lamba2019, Bouma2017, Lake2019], vamos usar o banco de dados (BD) Omniglot para testar one-shot learning. Este BD é uma coleção de 1623 caracteres de 50 diferente alfabetos. Há 20 exemplos escritos por diferentes pessoas para cada um dos 1632 caracteres, na resolução 105×105. Há 964 caracteres para o treino e 659 caracteres para o teste e 20 exemplos para caractere.

Este problema seria "análogo" a treinar reconhecimento de face usando fotografias de 964 pessoas diferentes, com 20 fotos de cada pessoa. Depois, testar o reconhecimento de face usando fotografias de 659 outras pessoas.

Você pode baixar BD de [<u>Lake2019</u>], copiando as imagens images_background.zip (imagens de treino) e images_evaluation.zip (imagens de teste) do diretório "python".

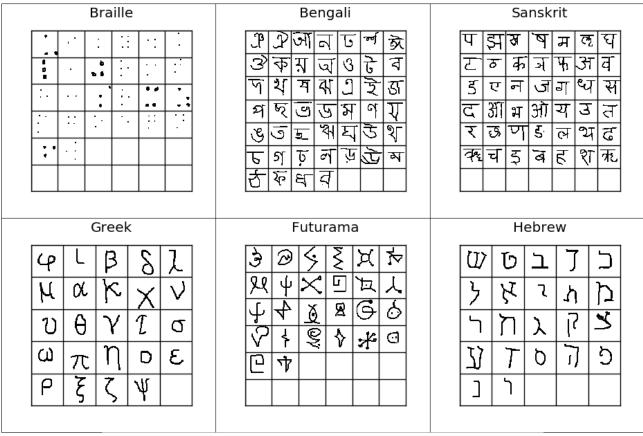


Figura 1: Alguns caracteres de Omniglot. Imagem de [Bouma2017].

Este BD contém 20 imagens para cada caractere. Abaixo, exemplo de 20 imagens de um mesmo caractere:

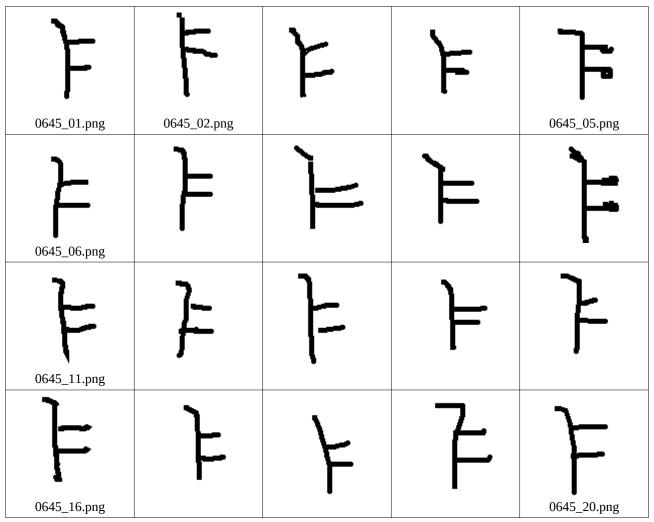


Figura 2: Exemplo de 20 imagens que representam o mesmo caractere.

O seguinte trecho de programa baixa e descompacta esse BD no diretório atual (no Colab ou no computador local):

Programa: Faz download do BD

[https://colab.research.google.com/drive/1lYp4y1 SSM8RFFPUnnlpCBhNI1iK0q2R?usp=sharing]

Após executar esse trecho, haverá dois subdiretórios no seu diretório atual: images_background (imagens de treino) e images_evaluation (imagens de teste), cada um com mais subdiretórios.

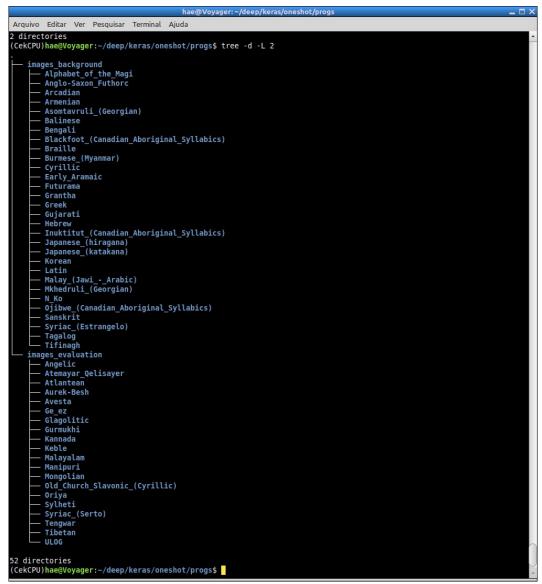


Figura 3: Estrutura do BD OmniGlot.

3. One-shot learning

Vamos usar o programa de Harshall Lamba, fazendo adaptações para simplificar o programa e facilitar o entendimento:

https://github.com/hlamba28/One-Shot-Learning-with-Siamese-Networks

```
"""oneshot.ipynb
Original file is located at
                  https://colab.research.google.com/drive/1lYp4y1_SSM8RFFPUnnlpCBhNI1iK0q2R
           """ O código seguinte baixa o BD Omniglot de: https://github.com/brendenlake/omniglot"""
         import os;
lista=['https://github.com/brendenlake/omniglot/raw/master/python/images_background.zip', \
         'https://github.com/brendenlake/omniglot/raw/master/python/images_evaluation.zip'] for url in lista:
             nomeArq=os.path.split(url)[1]
              if not os.path.exists(nomeArq):
    print("Baixando o arquivo",nomeArq,"para diretorio default",os.getcwd())
    os.system("wget -nc -U 'Firefox/50.0' "+url)
 15
             print("O arquivo", nomeArq, "ja existe no diretorio default", os.getcwd())
print("Descompactando arquivos novos de", nomeArq)
os.system("unzip -u "+nomeArq)
 16
17
 18
           """O programa abaixo é uma adaptação do programa de Harshall Lamba:
         https://github.com/hlamba28/One-Shot-Learning-with-Siamese-Networks
O artigo original de Harshall Lamba está em:
22
          https://towardsdatascience.com/one-shot-learning-with-siamese-networks-using-keras-17f34e75bb3d
24
25
        import sys
import numpy as np
import pandas as pd
from matplottib.pyplot import imread
import pickle, os, cv2, time
import matplotlib.pyplot as plt
26
27
28
29
30
31
32
        import tensorflow as tf
from tensorflow.keras.models import Sequential, load_model
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.layers import Conv2D, ZeroPadding2D, Activation, Input, concatenate
import tensorflow.keras.initializers as initializers
from tensorflow.keras.models import Model
from tensorflow.keras.layers import BatchNormalization, MaxPooling2D, Concatenate
from tensorflow.keras.layers import Layer, Lambda, Flatten, Dense
from tensorflow.keras.initializers import glorot_uniform
from tensorflow.keras.regularizers import l2
from tensorflow.keras.import backend as K
from sklearn.utils import shuffle
import numpy.random as rng
 45
46
47
48
        """Coloque abaixo os diretórios do seu ambiente de trabalho"""
train_folder = "./images_background/"
val_folder = './images_evaluation/'
save_path = './'
model_path = './'
 49
50
51
         # Funcao para carregar imagens
def loadimgs(path,n = 0):
    #path => Path of train directory or test directory
52
53
              loadimgs(path, n = 0),
#path => Path of train directory or test ulrector,
X=[1; y=[]
cat_dict = {}; lang_dict = {}; curr_y = n
# we load every alphabet seperately so we can isolate them later
for alphabet in os.listdir(path):
    print("loading alphabet: " + alphabet)
    lang_dict[alphabet] = [curr_y,None]
    alphabet_path = os.path.join(path,alphabet)
    for letter in os.listdir(alphabet_path):
        cat_dict[curr_y] = (alphabet, letter)
        category_images=[]
    letter_path = os.path.join(alphabet_path, letter)
    # read all the images in the current category
    for filename in os.listdir(letter_path):
        image_path = os.path.join(letter_path, filename)
        image = imread(image_path)
        category_images.append(image)
        y.append(curr_y)
try:
        vannend(np.stack(category_images))
54
56
57
58
 59
60
61
62
63
64
65
66
67
68
 69
70
71
72
73
74
75
76
77
                                      X.append(np.stack(category_images))
# edge case - last one
except ValueError as e:
    print(e); print("error - category_images:", category_images)
                                       curr y +=
                  lang_dict[alphabet][1] = curr_y - 1
y = np.vstack(y); X = np.stack(X)
return X,y,lang_dict
 78
79
 80
         # Carrega as imagens de treino
82
         Xtrain, ytrain, train_classes=loadimgs(train_folder)
        # Carrega as imagens de teste
Xval,yval,val_classes=loadimgs(val_folder)
85
86
87
        # Verifica o formato dos dados lidos
print(Xtrain.shape)
print(Xtrain[0,0,70])
print(ytrain.shape)
89
90
91
         print(ytrain[0:5])
```

```
print(train_classes)
 94
       print(Xval.shape)
       # Funcao que constroi a rede siamesa
 96
             get_siamese_model(input_shape):
#Model architecture based on the one provided in: http://www.cs.utoronto.ca/~gkoch/files/msc-thesis.pdf
 98
99
100
             left_input = Input(input_shape); right_input = Input(input_shape)
             seq = Sequential()
101
             103
            105
106
107
             seq.add(MaxPooling2D())
seq.add(Conv2D(128, (4,4), activation='relu', kernel_initializer=initializers.RandomNormal(stddev=1e-2),
bias_initializer=initializers.RandomNormal(mean=0.5, stddev=1e-2), kernel_regularizer=l2(2e-4)))
108
110
            112
113
114
115
117
118
119
                               bias_initializer=initializers.RandomNormal(mean=0.5, stddev=1e-2)))
            # Generate the encodings (feature vectors) for the two images encoded_l = seq(left_input); encoded_r = seq(right_input)
120
121
122
            # Add a customized layer to compute the absolute difference between the encodings
L1_distance = K.abs(encoded_l-encoded_r)
124
125
126
             # Add a dense layer with a sigmoid unit to generate the distance score
            127
128
129
             siamese_net = Model(inputs=[left_input,right_input],outputs=prediction)
131
             # return the model
             return siamese_net, seq
132
133
      # Execute esta celula para construir a rede "do zero" e imprimir a arquitetura
model, seq = get_siamese_model((105, 105, 1))
model.summary()
134
136
       seq.summary()
from tensorflow.keras.utils import plot_model
137
138
      plot_model(model, to_file=os.path.join(save_path, "siamese_net.png"))
plot_model(seq, to_file=os.path.join(save_path, "seq_net.png"))
optimizer = Adam(learning_rate = 0.00006)
model.compile(loss="binary_crossentropy", optimizer=optimizer, metrics=['accuracy'])
139
140
141
143
144
       # Execute esta celula para carregar a rede ja treinada
145
      # execute esta cettuta para carregar a rede ja treinada import os; import gdown url="https://drive.google.com/uc?id=1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q" nomeArq="oneshot.h5" if not os.path.exists(nomeArq): print("Baixando o arquivo",nomeArq,"para diretorio default",os.getcwd()) gdown.download(url, nomeArq, quiet=False)
146
148
150
151
152
       print("0 arquivo",nomeArq,"ja existe no diretorio default",os.getcwd())
model=load_model("oneshot.h5")
153
155
      # Funcao que pega uma lote de pares de imagens
# Metade dos pares de classes diferentes e outra metade dos pares de classes iguais
def get_batch(batch_size,s="train"):
    """Create batch of n pairs, half same class, half different class"""
    if s == 'train':
157
159
160
161
162
                  X = Xtrain; categories = train_classes; replace=False
            164
165
             n_{classes}, n_{examples}, w, h = X.shape
166
            categories = rng.choice(n_classes, size=(batch_size,), replace=replace)
pairs=[np.zeros((batch_size, h, w,1)) for i in range(2)]
targets=np.ones((batch_size,))
targets[batch_size//2:] = 0
167
169
170
             for i in range(batch_size):
171
                  i in range(batch_size):
category = categories[i]
idx_1 = rng.randint(0, n_examples)
pairs[0][i,:,:,:] = X[category, idx_1].reshape(w, h, 1)
idx_2 = rng.randint(0, n_examples)
# pick images of same class for 1st half, different for 2nd
if i >= batch_size // 2:
    category_2 = category
172
173
174
176
177
178
179
            # add a random number to the category modulo n classes to ensure 2nd image has a different category
    category_2 = (category + rng.randint(1,n_classes)) % n_classes
pairs[1][i,:,:,:] = X[category_2,idx_2].reshape(w, h,1)
return pairs, targets
181
183
184
      # Escolhe aleatoriamente lote de 4 pares de imagens e imprime
# 2 pares da mesma classe e 2 de classes diferentes
pairs,targets=get_batch(4)
185
186
      pairs,targets=get_batch(4)
print(pairs[0].shape)
print(pairs[1].shape)
print(targets.shape)
f = plt.figure(figsize=(2,4))
for i in range(4):
    f.add_subplot(4,2,2*i+1)
    plt.imshow(np.squeeze(pairs[0][i]), cmap="gray")
    plt.axis("off");
    f.add_subplot(4,2,2*i+2)
188
190
191
192
193
195
          f.add_subplot(4,2,2*i+2)
         plt.imshow(np.squeeze(pairs[1][i]), cmap="gray")
plt.axis("off");
197
```

Programa 1: One shot learning [https://colab.research.google.com/drive/1lYp4y1_SSM8RFFPUnnlpCBhNI1iK0q2R?usp=sharing]

3.1 Carregar imagens

A função *loadimgs* carrega o BD. Após ter carregado as imagens, executando:

```
Xtrain,ytrain,train_classes=loadimgs(train_folder)
print(Xtrain.shape)
print(Xtrain[0,0,70])
print(ytrain.shape)
print(ytrain[0:41])
print(train_classes)
```

Obtemos a seguinte saída:

Indicando que tensor *Xtrain* possui 964 entradas (caracteres) e cada entrada com 20 imagens 105×105. Os valores dos pixels das imagens são 0 (preto) ou 1 (branco).

O vetor *ytrain* possui 19280=964×20 entradas que indicam o caractere correspondente a cada imagem. Como há 20 imagens para cada caractere, as entradas 0 a 19 são de caractere 0, as entradas de 20 a 39 são de caractere 1, etc.

O dicionário *train_classes* indica quais caracteres pertencem a cada alfabeto. Os caracteres de 0 a 22 pertencem ao alfabeto 'Syriac_(Estrangelo)', os caracteres 23 a 63 pertencem ao alfabeto 'Mkhedruli_(Georgian)', etc. Não usaremos este dado na nossa solução.

3.2 Rede siamesa

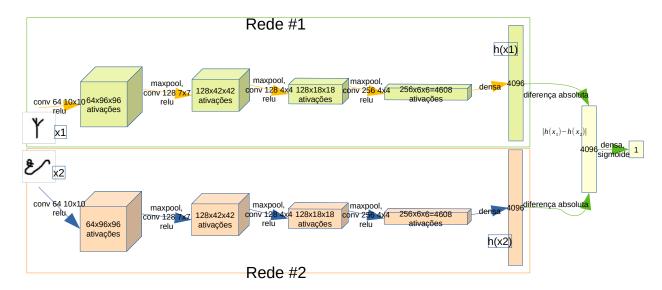


Figura 4: Uma rede siamesa consiste de duas redes completamente iguais, inclusive os parâmetros (pesos e vieses iguais).

O termo "siamesa" significa gêmeos que nascem ligados por uma parte do corpo. A rede siamesa consiste de duas redes convolucionais completamente iguais: as duas redes possuem estruturas e todos os parâmetros (pesos e vieses) iguais, ilustrada na figura acima. Na verdade, não temos duas redes mas uma única rede que recebe duas imagens diferentes e gera duas saídas diferentes (correspondentes às duas imagens de entrada). Assim, talvez a melhor representação seja a figura abaixo.

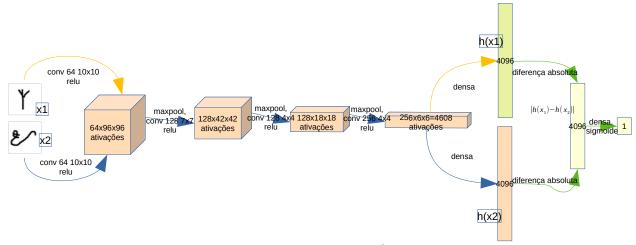


Figura 5: Na verdade, uma rede siamesa consiste de uma única rede utilizada para processar duas imagens diferentes.

Na figura acima, as duas imagens de entrada x_1 e x_2 passam pela mesma rede, gerando dois vetores de atributos $h(x_1)$ e $h(x_2)$. A rede calcula a diferença absoluta $|h(x_1)-h(x_2)|$ entre os dois vetores, gerando o vetor de 4096 diferenças absolutas. O vetor de diferenças passa por uma camada densa seguida de sigmoide para resultar no valor de saída entre 0 e 1. Queremos que a saída seja próxima de "0" se as duas imagens de entrada representarem caracteres iguais, e que seja próxima de "1" caso contrário.

A função *get_siamese_model* constroi e devolve a rede *siamese_net*. Além disso, devolve também a rede *seq*, a parte da rede que é compartilhada para processar as duas imagens. Copio abaixo essa função.

```
97
98
           get_siamese_model(input_shape):
left_input = Input(input_shape)
99
100
           right_input = Input(input_shape)
101
           # Convolutional Neural Network
          103
104
105
106
107
          RETURE LIMITALIZET=INITIALIZETS.RANDOMNormal(stddev=1e-2), bias_initializer=initializers.RandomNormal(mean=0.5, stddev=1e-2), kernel_regularizer=l2(2e-4))) seq.add(MaxPooling2D()) seq.add(Conv2D(128, (4,4), activation='relu', kernel_initializer=initializers.RandomNormal(stddev=1e-2), bias_initializer=initializers.RandomNormal(mean=0.5, stddev=1e-2), kernel_regularizer=l2(2e-4))) seq.add(MaxPooling2D())
108
109
110
111
112
          seq.add(Conv2D(256, (4, 4), activation='relu', kernel_initializer=initializers.RandomNormal(stddev=1e-2), bias_initializer=initializers.RandomNormal(mean=0.5, stddev=1e-2), kernel_regularizer=l2(2e-4)))
113
114
115
          116
117
118
119
120
121
122
123
124
           # Generate the encodings (feature vectors) for the two images
          encoded_l = seq(left_input)
encoded_r = seq(right_input)
125
126
          L1_distance = K.abs(encoded_l-encoded_r)
127
128
129
          siamese_net = Model(inputs=[left_input,right_input],outputs=prediction)
          return siamese_net, seq
```

Programa 2: Trecho do programa 1 que constrói a rede siamesa.

Essa função constrói a rede *seq* compartilhada (linhas 102-119). Essa rede processa as duas imagens e calcula a diferença absoluta (L1).

Depois de treinada, é possível usar esta rede de duas formas:

- a) Dadas duas imagens de dois caracteres, calcular a medida da diferença entre elas usado a rede siamese_net.
 - b) Dada uma imagem de um caractere, calcular os seus atributos usando a sub-rede seq.

Lembrete para mim: Para próximo ano, diminuir a quantidade de parâmetros das redes densas. Experimentar outras estruturas de redes. Lembrete: Retirar a última camada densa para comparar diretamente atributos .

```
Model: "sequential"
 Layer (type)
                                Output Shape
                                                              Param #
 conv2d (Conv2D)
                                 None,
                                        96,
                                            96, 64)
                                                              6464
 max_pooling2d (MaxPooling2D
                                (None,
                                        48,
                                             48,
                                                 64)
                                                             0
 conv2d_1 (Conv2D)
                                 None,
                                        42,
                                            42, 128)
                                                              401536
                                 (None, 21, 21, 128)
(None, 18, 18, 128)
 max_pooling2d_1 (MaxPooling
                                 ίNone,
 conv2d_2 (Conv2D)
                                                              262272
 max_pooling2d_2 (MaxPooling
                                 (None,
                                        9, 9, 128)
 conv2d_3 (Conv2D)
flatten (Flatten)
                                 (None,
                                        6, 6, 256)
                                                              524544
                                 (None,
                                        9216)
 dense (Dense)
                                                              37.752.832
                                 (None, 4096)
                                                             ========
Total params: 38,947,648
Trainable params: 38,947,648
Non-trainable params: 0
```

Figura 6: Rede seq

```
Model: "model"
 Layer (type)
                                       Output Shape
                                                                Param #
                                                                               Connected to
 input_1 (InputLayer)
                                       [(None, 105, 105, 1
                                                                Θ
 input_2 (InputLayer)
sequential (Sequential)
                                       [(None, 105,
(None, 4096)
                                                      105, 1
                                                                0
                                                                38947648
                                                                                input_1[0][0]'
                                                                                                         'input_2[0][0]']
                                                                                 'sequential[0][0]', 'sequ'
'tf.math.subtract[0][0]']
'tf.math.abs[0][0]']
                                                                                                        'sequential[1][0]']
 tf.math.subtract (TFOpLambda)
                                       (None, 4096)
                                                                0
 tf.math.abs (TFOpLambda)
                                       (None, 4096)
 dense_1 (Dense)
                                       (None, 1)
                                                                4097
Total params: 38,951,745
Trainable params: 38,951,745
Non-trainable params: 0
```

Figura 7: Rede siamese_net

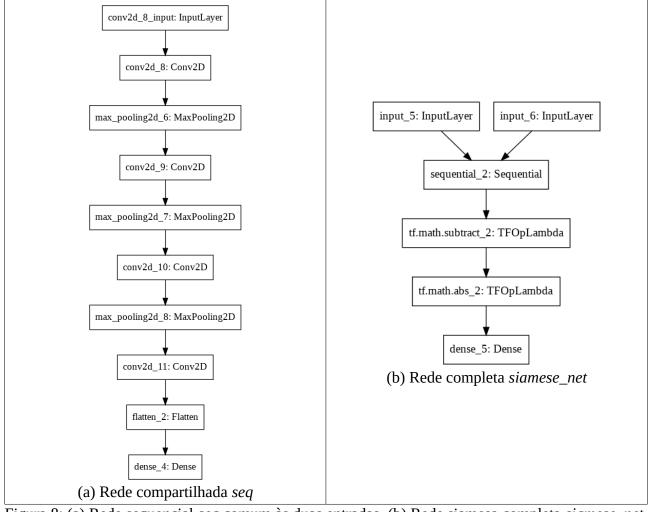


Figura 8: (a) Rede sequencial *seq* comum às duas entradas. (b) Rede siamesa completa *siamese_net*, que utiliza a rede sequencial *seq* para processar as duas imgens.

3.3 Gerar pares de imagens

A função *get_batch* gera aleatoriamente *batch_size* pares de imagens, metade delas de classes diferentes (distância "1") e outra metade de classes iguais (distância "0"). Por exemplo:

```
pairs,targets=get_batch(4)
```

gera 4 pares de imagens, metade com rótulo "1" e outra metade com rótulo "0":



Figura 9: Alguns lotes com classes diferentes "1" e iguais "0"

Vamos alimementar a rede siamesa com lotes de pares de imagens como acima.

3.4 Treinar o modelo

Treinando o modelo, obtemos saída como:

```
Loss=4.495485 Accuracy=0.500000
Epoca=
          0
Epoca= 1000
             Loss=0.818139 Accuracy=0.687500
Epoca= 2000
            Loss=0.417647 Accuracy=0.812500
Epoca= 3000
            Loss=0.357279 Accuracy=0.906250
Epoca= 4000
            Loss=0.377392 Accuracy=0.875000
Epoca= 5000
            Loss=0.350694 Accuracy=0.875000
Epoca= 6000
             Loss=0.235795 Accuracy=0.937500
Epoca= 7000
             Loss=0.368585 Accuracy=0.843750
Epoca= 8000
             Loss=0.262728 Accuracy=0.937500
Epoca= 9000
             Loss=0.280405 Accuracy=0.968750
Epoca=10000
             Loss=0.237525 Accuracy=0.968750
             Loss=0.181315 Accuracy=0.968750
Epoca=11000
Epoca=12000
             Loss=0.339775 Accuracy=0.875000
Epoca=13000
             Loss=0.296000 Accuracy=0.906250
Epoca=14000
             Loss=0.193697 Accuracy=0.968750
Epoca=15000
             Loss=0.236511 Accuracy=0.968750
Epoca=16000
            Loss=0.322566 Accuracy=0.968750
Epoca=17000
             Loss=0.266656 Accuracy=0.968750
Epoca=18000
             Loss=0.149310 Accuracy=1.000000
             Loss=0.219586 Accuracy=0.968750
Epoca=19000
```

Indicando que a função de perda diminui e acuracidade aumenta ao longo das épocas.

3.5 Testar o modelo

Depois de treinar a rede, temos um modelo que recebe duas imagens e retorna uma "nota" entre 0 e 1 indicando se as duas imagens representam (ou não) o mesmo caractere. Para testar o modelo, Lamba [Lamba2019] faz um teste complexo chamado "N-way one-shot learning". Vamos fazer um teste muito mais simples que também consegue mostrar a efetividade do *one-shot learning*. Vamos

gerar aleatoriamente *n* pares de imagens, metade representando caracteres iguais e outra metade caracteres diferentes. Depois, vamos alimentar esses pares de imagens à rede siamesa. Consideraremos que, se a resposta da rede for menor que 0,5, a rede classificou o par como caracteres iguais. Fazendo isso com 10000 pares de imagens, obtive taxa de acerto 89,41%.

Exercício: Em vez de limiarizar em 0,5 como acima, trace a curva ROC e calcule a taxa de acerto no ponto EER (equal error rate).

Exercício: Escreva um programa que testa "16-way one shot learning". O problema é calcular, dados um caractere QX à esquerda e mais 16 caracteres à direita (figura abaixo), qual dos 16 caracteres à direita corresponde à mesma classe que QX. Só há uma única resposta correta.

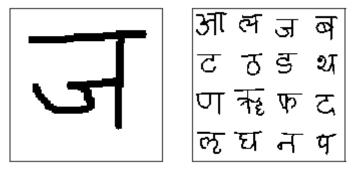


Figura 10: 16-way one shot learning.

Para isso:

a) Carregue o modelo oneshot.h5 já treinado com o programa 1 (oneshot.py):

https://drive.google.com/file/d/1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q

```
# Execute esta celula para carregar a rede ja treinada
import os; import gdown
url="https://drive.google.com/uc?id=1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q"
nomeArq="oneshot.h5"
if not os.path.exists(nomeArq):
    print("Baixando o arquivo",nomeArq,"para diretorio default",os.getcwd())
    gdown.download(url, nomeArq, quiet=False)
else:
    print("O arquivo",nomeArq,"ja existe no diretorio default",os.getcwd())
model=load_model("oneshot.h5")
```

- b) Escolha aleatoriamente um caractere QX e outros 16 caracteres de diferentes classes dos quais apenas um é da mesma classe que QX, como na figura acima.
- c) Verifique se o modelo consegue acertar qual é o caractere da mesma classe que QX.
- d) Repita os passos (b) e (c) 1000 vezes e verifique a taxa de acerto.

[Em elaboração

Exercício: Como vimos, há 964 caracteres para o treino e 659 caracteres para o teste no BD Omniglot, com 20 exemplos para cada caractere. Além disso, disponibilizei o modelo *oneshot.h5* já treinado usando as caracteres de treino pelo programa 1 (oneshot.py):

https://drive.google.com/file/d/1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q

Considerando as imagens 0 a 9 dos 659 caracteres de teste como modelos, classifique as imagens 10 a 19 dos 659 caracteres de teste. Acho que precisa retirar a última camada densa para que possa fazer este exercício.

Exercício: Escreva um programa que:

a) Carrega o modelo oneshot.h5 já treinado com o programa 1 (oneshot.py):

https://drive.google.com/file/d/1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q

```
# Execute esta celula para carregar a rede ja treinada
import os; import gdown
url="https://drive.google.com/uc?id=1PAyiW-0_dyti5Fdp_qwgQRqGen4GwY7q"
nomeArq="oneshot.h5"
if not os.path.exists(nomeArq):
    print("Baixando o arquivo",nomeArq,"para diretorio default",os.getcwd())
    gdown.download(url, nomeArq, quiet=False)
else:
    print("O arquivo",nomeArq,"ja existe no diretorio default",os.getcwd())
model=load_model("oneshot.h5")
```

- b) Lê nomes de duas imagens de OmniGlot e mostra as duas imagens na tela, juntamente com a distância (a resposta da rede) entre elas.
- c) Teste o seu programa fornecendo 3 pares de imagens de caracteres iguais e 3 pares de imagens de caracteres diferentes. Qual foi a taxa de acerto?

II. Reconhecimento facial

1. Introdução

Hoje em dia, estamos bem acostumados com a identificação das pessoas usando reconhecimento facial. Por exemplo, os telefones celulares podem ser desbloqueados através de reconhecimento facial. O acesso a muitos prédios ou condomínios é feito pelo reconhecimento facial. Embarque aéreo por reconhecimento facial está disponível na ponte aérea entre Congonhas (SP) e Santos Dumont (RJ), dispensando a apresentação de documentos de identidade (31/10/2022)

https://www.gov.br/pt-br/noticias/transito-e-transportes/2022/08/entrou-em-funcionamento-a-1a-ponte-aerea-biometrica-do-mundo-para-embarque-de-passageiros para la compara la co

Tipicamente, o reconhecimento facial compreende 4 etapas:

- Etapa 1: Localizar a face dentro da imagem.
- Etapa 2: Extrair a face da imagem e alinhá-la numa posição padronizada.
- Etapa 3: Converter a imagem da face em atributos (conhecidos como impressão facial). Alguns atributos que caracterizam a face de uma pessoa serão extraídos a partir da imagem da face recortada e alinhada.
- Etapa 4: Localizar a correspondência no BD. A impressão facial será utilizada para fazer busca num BD de rostos conhecidos.

Aqui, estamos mais interessados na etapa 3 (extração de impressão facial da imagem), pois já conhecemos (mais ou menos) como se pode resolver as etapas 1, 2 e 4 (por exemplo, usando o algoritmo de Viola e Jones, transformações geométricas e busca do vizinho mais próximo).

Antes de *redes convolucionais* e *aprendizado profundo*, eram usadas técnicas como *EigenFaces*, *FisherFaces* e *LBPH* para extrair a impressão facial. O site abaixo traz um bom tutorial de técnicas clássicas de reconhecimento de faces em OpenCV:

http://docs.opency.org/2.4/modules/contrib/doc/facerec/facerec tutorial.html

Os exercícios-programas de 2017 também servem como exemplos de reconhecimento facial:

http://www.lps.usp.br/hae/psi5796/ep2-2017/index.html http://www.lps.usp.br/hae/psi3471/ep2-2017/index.html

Como vimos no início desta aula, é possível usar pares de imagens de pessoas iguais e diferentes para treinar uma rede siamesa. A rede treinada irá extrair a "impressão facial", isto é, um vetor de atributos. As imagens de uma mesma pessoa irão gerar "impressões faciais" semelhante, enquanto que as imagens de pessoas diferentes irão gerar "impressões faciais" diferentes.

2. Biblioteca DeepFace

Existem modelos de redes convolucionais prontos para serem usados. Aparentemente, *DeepFace* de Sefik Serengil é uma das bibliotecas mais populares.

https://pypi.org/project/deepface/

https://github.com/serengil/deepface

https://viso.ai/computer-vision/deepface/

https://sefiks.com/2020/05/01/a-gentle-introduction-to-face-recognition-in-deep-learning/

https://www.youtube.com/playlist?list=PLsS_1RYmYQQFdWqxQggXHynP1rqaYXv_E

Esses sites e vídeos são bem didáticos e é possível usar os modelos gerados por grandes empresas, como Microsoft, Google, Facebook, etc. Serengil faz uma comparação dos diferentes modelos (VGG-Face da Oxford, OpenFace da Carnegie Mellon, DeepFace da Facebook e FaceNet da Google) no vídeo abaixo:

https://www.youtube.com/watch?v=i_MOwvhbLdI

Conforme já vimos no one-shot learning, reconhecimento facial depende da extração de "impressão facial" a partir das imagens das faces. A comparação entre duas impressões faciais (dois vetores) pode ser feita calculando o ângulo α ou distância euclidiana d entre os dois vetores. Também poderia usar a diferença absoluta, como fizemos em OmniGlot.

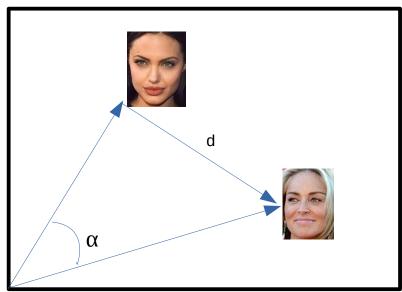


Figura 11: Reconhecimento facial calcula a diferença entre impressões faciais como distância euclidiana d ou cosseno dos ângulos α .

Serengil testou vários os modelos e métricas de distância, chegando à conclusão de que o modelo com a maior taxa de acerto é FaceNet da Google usando distância euclidiana, com taxa de acerto de 98,57%. FaceNet com distância cosseno atinge a segunda maior taxa de acerto 98,21% mas com a vantagem de que a distância estará limitada ao intervalo [-1; +1].

O programa 3 exemplifica o uso de *DeepFace*.

Antes de mais nada, é necessário instalar o módulo DeepFace: pip install deepface OU pip3 install deepface

```
__
"""face1b.ipynb
     https://colab.research.google.com/drive/1yL3KZnKZ0j929htCIT66j2HuqVHQ8zat
url='http://www.lps.usp.br/hae/apostila/face.zip'
import os; nomeArq=os.path.split(url)[1]
if not os.path.exists(nomeArq):
  print("Baixando o arquivo",nomeArq,"para diretorio default",os.getcwd())
os.system("wget -nc -U 'Firefox/50.0' "+url)
print("O arquivo", nomeArq, "ja existe no diretorio default", os.getcwd())
print("Descompactando arquivos novos de", nomeArq)
os.system("unzip -u "+nomeArq)
#face1b.pv
#!pip3 install deepface
from deepface import DeepFace
model_name="Facenet"; distance_metric="cosine"
img1_path="sharon_stone1.jpg"; img2_path="sharon_stone2.jpg"
resp = DeepFace.verify (img1_path=img1_path, img2_path=img2_path,
  model_name=model_name, distance_metric=distance_metric)
print("Comparando",img1_path,"com",img2_path,":")
print(resp,"\n")
img1_path="angelina_jolie1.jpg"; img2_path="angelina_jolie2.jpg"
resp = DeepFace.verify (img1_path=img1_path, img2_path=img2_path,
  model_name=model_name, distance_metric=distance_metric)
print("Comparando",img1_path,"com",img2_path,":")
print(resp, "\n")
img1_path="angelina_jolie1.jpg"; img2_path="sharon_stone1.jpg"
resp = DeepFace.verify (img1_path=img1_path, img2_path=img2_path,
    model_name=model_name,distance_metric=distance_metric)
print("Comparando",img1_path,"com",img2_path,":")
print(resp,"\n")
img1_path="angelina_jolie1.jpg"; img2_path="sharon_stone2.jpg"
resp = DeepFace.verify (img1_path=img1_path, img2_path=img2_path,
    model_name=model_name,distance_metric=distance_metric)
print("Comparando",img1_path,"com",img2_path,":")
print(resp, "\n")
```

Programa 3: Exemplo de uso de DeepFace.

https://colab.research.google.com/drive/1yL3KZnKZOj929htCIT66j2HuqVHQ8zat?usp=sharing

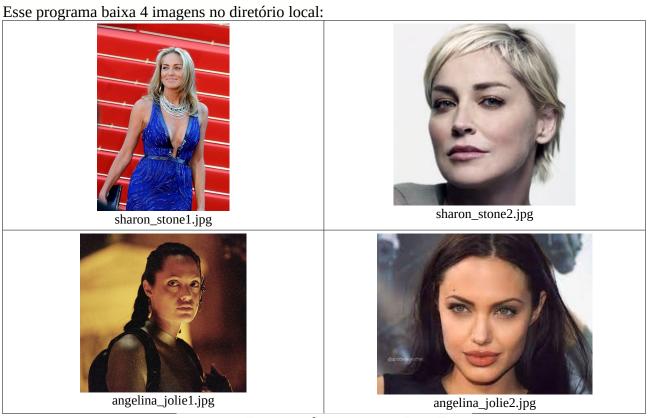


Figura 12: Faces usadas para testar DeepFace.

Depois, compara algumas pares de imagens, obtendo:

```
Comparando sharon_stone1.jpg com sharon_stone2.jpg :
{'verified': True, 'distance': 0.2302723612803883, 'threshold': 0.4, 'model': 'Facenet',
'detector_backend': 'opencv', 'similarity_metric': 'cosine'}

Comparando angelina_jolie1.jpg com angelina_jolie2.jpg :
{'verified': False, 'distance': 0.8713807300927271, 'threshold': 0.4, 'model': 'Facenet',
'detector_backend': 'opencv', 'similarity_metric': 'cosine'}

Comparando angelina_jolie1.jpg com sharon_stone1.jpg :
{'verified': False, 'distance': 0.9549059975525636, 'threshold': 0.4, 'model': 'Facenet',
'detector_backend': 'opencv', 'similarity_metric': 'cosine'}

Comparando angelina_jolie1.jpg com sharon_stone2.jpg :
{'verified': False, 'distance': 1.0752758541684009, 'threshold': 0.4, 'model': 'Facenet',
'detector_backend': 'opencv', 'similarity_metric': 'cosine'}
```

Os acertos estão marcados em verde e os erros em vermelho. Repare que o programa errou na comparação entre *angelina_jolie1* e *angelina_jolie2*, dizendo que as fotos são de pessoas diferentes. Se vê que o modelo está longe de ser perfeito...

Esta biblioteca possui a função *find*, que acha rapidamente as faces mais parecidas com a face de busca num BD de faces.

3. Exemplo do exercício-programa de PSI5790 de 2023

O exercício-programa de 2023

http://www.lps.usp.br/hae/psi5790/ep1-2023/index.html

pedia para reconhecer os rostos de 5 atores de vingadores num BD com poucas amostras (50 imagens de cada ator) através de dois métodos:

- 1) Usando qualquer método de classificação de imagens com CNN.
- 2) Usando DeepFace.

Pedia que se fizesse 2-fold cross validation, isto é, usar a metade das imagens para treino e a outra metade para teste, e depois inverter os conjuntos de treino e de teste.



Figura 13: Exemplos de imagens faciais dos 5 atores de vingadores.

Os resultados obtidos por mim foram:

- 1) Usando CNN convencional treinada do zero para classificar imagens, obtive erro médio de 30%.
- 2) Usando DeepFace, obtive erro médio de 1,2%.

Isto mostra a vantagem de usar uma rede pré-treinada para reconhecer faces.

Exercício: Pegue 3 fotos suas e 3 fotos de diferentes colegas seus. Para cada uma das 3 fotos suas, ache o rosto mais parecido entre as 5 imagens restantes – se o sistema for bom, deve dizer que o rosto mais parecido é uma das 2 fotos suas e a distância entre as 2 imagens deve ser menor que o threshold, indicando que são fotos da mesma pessoa. Para cada foto do seu colega, procure o rosto

mais parecido entre as 5 imagens restantes — se o sistema for bom, as distâncias da foto para cada um dos 5 rostos deve ser maior do que o threshold, indicando que nenhum dos 5 rostos corresponde à foto.

[PSI3472-2023. Aula 13 parte 1. Fim]

Referências:

[Lamba2019] One Shot Learning with Siamese Networks Using Keras. https://towardsdatascience.com/one-shot-learning-with-siamese-networks-using-keras-17f34e75bb3d

 $[Brownlee 2019]\ One-Shot\ Learning\ for\ Face\ Recognition.\ {\tt https://machinelearningmastery.com/one-shot-learning-with-siamese-networks-contrastive-and-triplet-loss-for-face-recognition/}$

[Bouma2017] One Shot Learning and Siamese Networks in Keras. https://sorenbouma.github.io/blog/oneshot/

[Lake2019] Breden Lake, Omniglot data set for one-shot learning. https://github.com/brendenlake/omniglot